Estancia Académica

Punto 6 · Extracción de características histomorfológicas

Base de datos: BreaKHis | Magnificaciones: 40X y 100X | Alcance: análisis exploratorio de regiones segmentadas

1. Objetivo de la actividad

Obtener descriptores cuantitativos reproducibles a partir de imágenes BreaKHis de 40X y 100X y de las máscaras binarias generadas durante las etapas 1–5 (normalización de tinción, conversión HSV/Lab, umbralización y limpieza morfológica). El propósito es describir color, textura y geometría de regiones candidatas, antes de seleccionar características o entrenar modelos predictivos.

2. Entradas y condiciones de análisis

El programa utiliza el inventario_40x_100x.csv y las carpetas de resultados producidas por analisis_breakhis.py. Para cada imagen disponible se leen normalizada.png y limpia_hsv.png o limpia_lab.png. Se evalúan las condiciones original, Reinhard, Macenko y Vahadane solo si existen realmente los archivos correspondientes; una normalización no realizada no se simula.

La comparación requiere mantener el identificador de paciente, la clase, el subtipo, la magnificación, el método de normalización y la máscara utilizada en cada registro, para permitir análisis posteriores sin mezclar pacientes.

3. Características cuantitativas

Familia	Descriptores	Interpretación
Cobertura	Porcentaje de píxeles de máscara; número de componentes	Extensión de las regiones seleccionadas
Color	Medias y desviaciones RGB, HSV y Lab en la máscara	Distribución cromática de regiones candidatas
Textura GLCM	Contraste, homogeneidad, energía y correlación	Relación estadística de niveles de gris entre píxeles vecinos
Textura LBP	Histograma LBP uniforme (10 categorías) y entropía	Patrones locales de intensidad
Geometría	Área, perímetro, circularidad, solidez, aspecto y excentricidad	Forma de componentes conectados de la máscara

4. Procedimiento técnico

1. Leer el inventario y seleccionar registros con magnificaciones 40X o 100X y estado legible.

2. Identificar las combinaciones de normalización y máscara HSV/Lab que estén presentes en la carpeta de resultados.

3. Obtener componentes conectados tras limpieza morfológica y descartar componentes inferiores al área mínima configurada.

4. Calcular color y textura exclusivamente dentro de la región enmascarada. La GLCM toma pares de píxeles válidos dentro de la máscara para evitar bordes negros artificiales.

5. Guardar descriptores por imagen y por componente, más resúmenes agrupados y registro de errores.

5. Advertencias de validez

Las regiones obtenidas por umbralización cromática NO equivalen automáticamente a núcleos celulares, glándulas o células individualizadas. Los rasgos deben denominarse “características de regiones segmentadas” hasta contar con validación por anotaciones histológicas o un método de segmentación adecuado. Tampoco es correcto inferir diagnóstico clínico a partir de los resultados de este punto.

Las áreas y los perímetros se expresan en píxeles; no deben interpretarse como μm^2 ni μm ni compararse como tamaños biológicos equivalentes entre 40X y 100X sin calibración espacial. Las texturas dependen de resolución, magnificación, máscaras y parámetros de cálculo. Se reportarán estos parámetros junto con los resultados.

6. Archivos generados

- caracteristicas_por_imagen.csv: un registro por imagen × método × máscara, con medidas globales.
- caracteristicas_por_region.csv: un registro por componente detectado.
- resumen_grupos.csv: agregados por magnificación, clase, normalización y máscara.
- errores.csv: incidencias encontradas; no se rellenan los casos faltantes.

7. Instrucciones de ejecución

Instalación: python -m pip install -r requirements.txt

Prueba: python extraccion_caracteristicas.py --results "RUTA_A_RESULTADOS_1_5" --output resultados_punto_6 --limit 8

Ejecución completa: python extraccion_caracteristicas.py --results "RUTA_A_RESULTADOS_1_5" --output resultados_punto_6 --limit 0

8. Criterios de conclusión y siguiente fase

Se considerará concluido técnicamente el punto 6 cuando existan los archivos CSV, las incidencias estén revisadas y se hayan inspeccionado visualmente máscaras representativas de ambas magnificaciones, clases y métodos. La etapa posterior es comparar las características y evaluar su utilidad predictiva mediante separación por paciente, selección de atributos y entrenamiento de modelos, sin utilizar datos de prueba para definir umbrales o hiperparámetros.

9. Referencias metodológicas

Haralick, R. M., Shanmugam, K., & Dinstein, I. (1973). Textural Features for Image Classification. IEEE Transactions on Systems, Man, and Cybernetics, SMC-3(6), 610–621. https://doi.org/10.1109/TSMC.1973.4309314

Ojala, T., Pietikäinen, M., & Mäenpää, T. (2002). Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns. IEEE TPAMI, 24(7), 971–987. https://doi.org/10.1109/TPAMI.2002.1017623

Spanhol, F. A., Oliveira, L. S., Petitjean, C., & Heutte, L. (2016). A Dataset for Breast Cancer Histopathological Image Classification. IEEE Transactions on Biomedical Engineering, 63(7), 1455–1462. https://doi.org/10.1109/TBME.2015.2496264